PROYECTO

# Sistema Inteligente de Análisis, Detección y Predicción de Gastos Personales

*Basado en Machine Learning*

**Técnico en Procesamiento de Datos para Modelos de Inteligencia Artificial**

## 1. Planteamiento del Problema

En la actualidad, el manejo de las finanzas personales se ha vuelto más complejo debido al crecimiento acelerado de los pagos digitales, las suscripciones en línea y los gastos recurrentes automáticos. A pesar de esta realidad, la mayoría de las personas carece de herramientas que les permitan comprender con claridad sus propios patrones de consumo.

El problema central radica en que las aplicaciones financieras tradicionales —como hojas de cálculo o registradores básicos de gastos— se limitan a almacenar y visualizar datos, pero no son capaces de interpretarlos, aprender de ellos ni anticipar comportamientos futuros. Como consecuencia, el usuario toma decisiones económicas basadas en intuición y no en evidencia, lo que puede derivar en:

- Gastos repetitivos o innecesarios no detectados a tiempo.
- Ausencia de ahorro por falta de conciencia del consumo real.
- Endeudamiento progresivo originado en hábitos difíciles de identificar sin análisis.
- Dificultad para proyectar el comportamiento financiero futuro.

Esta problemática afecta a un amplio espectro de la población, independientemente del nivel de ingresos, y representa una oportunidad clara para aplicar técnicas de inteligencia artificial que transformen los datos en decisiones.

## 2. Justificación

Este proyecto responde a una necesidad concreta y cotidiana: la falta de control inteligente sobre las finanzas personales. A diferencia de las soluciones existentes, el sistema propuesto no se limita a registrar información, sino que la interpreta activamente mediante algoritmos de Machine Learning.

La justificación del proyecto se sustenta en tres dimensiones:

| | |
|---|---|
| **Social** | Contribuye a mejorar la calidad de vida económica de los usuarios al facilitarles el control financiero con herramientas accesibles e inteligentes. |
| **Técnica** | Aplica de forma práctica algoritmos de clasificación, regresión y detección de anomalías sobre datos reales, demostrando la utilidad del Machine Learning en contextos cotidianos. |
| **Académica** | Integra las competencias adquiridas en el programa de formación: procesamiento de datos, análisis estadístico, modelado con inteligencia artificial y despliegue de soluciones. |

## 3. Objetivo General

Desarrollar un sistema inteligente basado en Machine Learning que permita analizar el historial de gastos personales, identificar patrones de comportamiento financiero, detectar anomalías y predecir el consumo futuro del usuario, con el fin de apoyar la toma de decisiones económicas informadas.

## 4. Objetivos Específicos

- Recolectar y preprocesar un conjunto de datos de gastos personales proveniente de fuentes verificables (Kaggle: Personal Finance Dataset).
- Identificar y visualizar patrones de consumo mediante análisis exploratorio de datos (EDA).
- Implementar modelos de regresión (Random Forest Regressor, XGBoost) para la predicción de gastos futuros.
- Aplicar algoritmos de detección de anomalías (Isolation Forest) para identificar gastos inusuales o atípicos.
- Clasificar automáticamente las transacciones por categoría usando modelos de clasificación supervisada.
- Evaluar el rendimiento de los modelos mediante métricas estandarizadas (MAE, RMSE, F1-score).
- Desarrollar un dashboard interactivo en Streamlit que presente los resultados de forma clara y accionable.

## 5. Alcance del Proyecto

El sistema cubrirá las siguientes funcionalidades:

| Funcionalidad | Descripción | Incluido |
|---|---|---|
| Ingesta de datos | Carga de archivos CSV con transacciones personales | Sí |
| Preprocesamiento | Limpieza, normalización e ingeniería de características | Sí |
| Clasificación de gastos | Categorización automática por tipo de gasto | Sí |
| Predicción de gastos | Estimación del gasto futuro por período | Sí |
| Detección de anomalías | Identificación de transacciones inusuales | Sí |
| Recomendaciones | Sugerencias automáticas de optimización financiera | Sí |

| Funcionalidad | Descripción | Incluido |
|---|---|---|
| Dashboard visual | Interfaz interactiva con gráficas y alertas | Sí |
| Integración bancaria | Conexión directa con APIs de bancos | No (fase futura) |

## 6. Solución Propuesta

Se propone el desarrollo de un sistema modular compuesto por tres capas funcionales que trabajan de forma integrada:

### 6.1 Capa de Datos

Responsable de la ingesta, limpieza y transformación de los datos. El usuario carga un archivo CSV con su historial de transacciones, y el sistema lo preprocesa automáticamente para dejarlo listo para el modelado.

### 6.2 Capa de Modelos

Núcleo inteligente del sistema. Incorpora tres tipos de modelos de Machine Learning trabajando simultáneamente sobre los datos del usuario:

- Modelo de clasificación: categoriza cada gasto automáticamente (alimentación, transporte, ocio, servicios, etc.).
- Modelo de predicción: estima el gasto total esperado para el siguiente período usando Random Forest Regressor o XGBoost.
- Modelo de detección de anomalías: identifica transacciones estadísticamente inusuales mediante Isolation Forest.

### 6.3 Capa de Presentación

Dashboard interactivo desarrollado en Streamlit que muestra gráficas de evolución del gasto, alertas de anomalías, predicciones futuras y recomendaciones personalizadas generadas automáticamente a partir de los resultados de los modelos.

## 7. Metodología — CRISP-DM

El proyecto sigue la metodología estándar de la industria para proyectos de ciencia de datos: CRISP-DM (Cross-Industry Standard Process for Data Mining), la cual garantiza un proceso estructurado, reproducible y alineado con las mejores prácticas del área.

### 7.1 Comprensión del Negocio

Identificación del problema financiero central: la falta de análisis inteligente del comportamiento de gasto personal. Definición de los criterios de éxito del sistema y los indicadores de evaluación.

## 7.2 Comprensión y Fuentes de los Datos

Se utilizará el dataset 'Personal Finance & Spending Habits Dataset' disponible en Kaggle, el cual contiene más de 10.000 registros anonimizados de transacciones personales con las siguientes variables principales:

| Variable | Tipo | Descripción |
|---|---|---|
| fecha | datetime | Fecha de la transacción |
| monto | float | Valor del gasto en la moneda local |
| categoria | categórica | Tipo de gasto: alimentación, transporte, ocio, etc. |
| descripcion | texto | Detalle o concepto del gasto |
| ingreso_mensual | float | Ingreso del período correspondiente |
| saldo_disponible | float | Saldo disponible tras la transacción |

Como fuente complementaria, se generarán datos sintéticos con la librería Faker de Python, siguiendo las distribuciones estadísticas del dataset original, para simular comportamientos adicionales como gastos estacionales y anomalías controladas.

## 7.3 Preparación de los Datos

- Eliminación de registros duplicados y tratamiento de valores nulos.
- Normalización de variables numéricas con MinMaxScaler o StandardScaler según el modelo.
- Codificación de variables categóricas con LabelEncoder u OneHotEncoder.
- Ingeniería de características: gasto promedio semanal, variación porcentual mensual, ratio gasto/ingreso.
- Balanceo de clases con SMOTE para la detección de anomalías (clase minoritaria).

## 7.4 Modelado

Se aplicarán los siguientes algoritmos según el tipo de tarea:

| Tarea | Algoritmo | Librería |
|---|---|---|
| Clasificación de gastos | Random Forest Classifier | scikit-learn |

| Tarea | Algoritmo | Librería |
|---|---|---|
| Predicción de gasto futuro | XGBoost Regressor | xgboost |
| Detección de anomalías | Isolation Forest | scikit-learn |
| Análisis de series de tiempo | Prophet / ARIMA | prophet / statsmodels |

### 7.5 Evaluación

El rendimiento de cada modelo se medirá con métricas estandarizadas:

| Modelo | Métrica Principal | Métricas Secundarias |
|---|---|---|
| Clasificación | F1-Score (ponderado) | Accuracy, Precision, Recall |
| Regresión / Predicción | MAE (Error Absoluto Medio) | RMSE, $R^2$ |
| Detección de anomalías | Precisión en clase anómala | AUC-ROC, Recall |

### 7.6 Despliegue

El sistema se implementará como una aplicación web local desarrollada con Streamlit (Python), permitiendo al usuario cargar sus datos, visualizar los resultados y recibir recomendaciones sin necesidad de conocimientos técnicos.

## 8. Resultados Esperados

| Resultado | Indicador de Éxito |
|---|---|
| Clasificación automática de transacciones | F1-Score > 0.85 en el conjunto de prueba |
| Predicción de gastos futuros | MAE < 10% del gasto promedio mensual |
| Detección de anomalías | Precisión > 80% en transacciones atípicas |
| Dashboard funcional | Visualización clara de patrones, alertas y predicciones |
| Recomendaciones automáticas | Al menos 3 sugerencias personalizadas por análisis |

## 9. Valor Diferencial

Este proyecto se distingue de las soluciones financieras convencionales en aspectos clave:

| Característica | Herramienta Tradicional | Este Sistema |
|---|---|---|
| Registro de datos | Manual o semiautomático | Automático con carga de CSV |
| Análisis | Visualización básica | Modelos de ML adaptativos |
| Predicción | No disponible | XGBoost / Random Forest |
| Detección de irregularidades | No disponible | Isolation Forest |
| Recomendaciones | Reglas fijas o manuales | Generadas por el modelo |
| Adaptación al usuario | Ninguna | Aprende del comportamiento propio |

## 10. Stack Tecnológico

| Categoría | Herramienta / Librería | Uso |
|---|---|---|
| Lenguaje | Python 3.10+ | Desarrollo general del sistema |
| Machine Learning | scikit-learn, XGBoost | Modelos de clasificación, regresión y anomalías |
| Series de tiempo | Prophet, statsmodels | Predicción temporal de gastos |
| Procesamiento de datos | Pandas, NumPy | Limpieza, transformación y análisis |
| Visualización | Matplotlib, Seaborn, Plotly | Gráficas estadísticas e interactivas |
| Interfaz de usuario | Streamlit | Dashboard web interactivo |
| Generación de datos | Faker | Simulación de datos sintéticos |
| Balanceo de clases | imbalanced-learn (SMOTE) | Tratamiento de clases minoritarias |
| Entorno de desarrollo | Jupyter Notebook / VS Code | Desarrollo y documentación del código |

## 11. Conclusión

El Sistema Inteligente de Análisis, Detección y Predicción de Gastos Personales representa una solución innovadora y aplicable a una problemática real y cotidiana. A través de la implementación de técnicas de Machine Learning sobre datos financieros reales, el sistema es capaz de ir más allá del simple registro de transacciones: aprende del comportamiento del usuario, anticipa su consumo y genera recomendaciones concretas para optimizar su gestión económica.

Desde el punto de vista académico, el proyecto integra de forma coherente y aplicada los conocimientos centrales del programa de formación: procesamiento y limpieza de datos, análisis estadístico exploratorio, modelado con algoritmos de inteligencia artificial y despliegue de soluciones

funcionales. La metodología CRISP-DM garantiza un proceso riguroso, estructurado y alineado con los estándares de la industria.

La combinación de un modelo técnico sólido con una interfaz accesible y comprensible para el usuario final convierte a este proyecto en una propuesta de alto valor, tanto en su dimensión técnica como en su impacto social.